INFORME EJECUTIVO: Análisis Predictivo y Factores de Deserción Escolar en Bolivia (EH2025)

1. Introducción y Antecedentes

El análisis de la deserción escolar constituye un pilar fundamental para la formulación de políticas públicas orientadas al desarrollo del capital humano y la reducción de la desigualdad estructural en Bolivia. A pesar de los avances históricos en el acceso a la educación formal, la permanencia y conclusión de los ciclos educativos continúan enfrentando desafíos críticos asociados a factores socioeconómicos, geográficos y demográficos.

En este contexto, el presente estudio utiliza los microdatos oficiales de la Encuesta de Hogares 2025 (EH2025) del Instituto Nacional de Estadística (INE). El catálogo analítico comprende múltiples bases especializadas que permiten una aproximación multidimensional al fenómeno, destacando:

- `EH2025_Persona.sav`: Características sociodemográficas, educación y salud.
- `EH2025_Vivienda_1.sav`: Infraestructura y servicios básicos de la vivienda.
- `EH2025_Gastos_Alimentarios.sav` y `EH2025_Gastos_No_Alimentarios.sav`: Presión económica del hogar.
- `EH2025_Seguridad_Alimentaria.sav`, `EH2025_Equipamiento.sav` y `EH2025_Discriminacion.sav`: Variables contextuales de bienestar y vulnerabilidad.

Estos datos fueron procesados mediante herramientas de alta eficiencia computacional (DuckDB) y modelos de Machine Learning (XGBoost y Random Forest), con el propósito de identificar con precisión analítica los factores de riesgo determinantes del abandono escolar y proporcionar evidencia empírica para la intervención oportuna del Estado.

2. Metodología y Construcción de la Variable Objetivo

Para aislar la población en riesgo, el estudio se enfocó en una muestra depurada de **11,740 estudiantes en edad escolar** (rango de 5 a 20 años). A partir del diccionario de variables de la sección de educación dentro de `EH2025_Persona.sav`, se examinaron los siguientes campos clave:

- `s03a_04`: Inscripción o matriculación en la gestión 2025.
- `s03b_10`: Continuidad y asistencia regular a clases.
- `cmasi`: Condición de Matriculación y Asistencia calculada por el INE.

Al analizar la condición de asistencia en la muestra, se obtuvieron los siguientes valores absolutos:

- **Asiste:** 10,897 casos.
- **No matriculado:** 829 casos.
- **No asiste:** 14 casos.

Derivado de esto, se construyó una variable objetivo binaria de deserción (`desercion`), cuya distribución ajustada muestra que el **7.18%** de la población analizada se encuentra en condición de abandono o inasistencia escolar, frente a un **92.82%** que mantiene su continuidad educativa.

3. Hallazgos Clave y Patrones Geográficos / Socioeconómicos

A. Disparidades Departamentales (Tasa de Deserción)

El análisis geoespacial revela una marcada heterogeneidad en las tasas de deserción escolar a nivel nacional:

- **Pando** registra la tasa más elevada del país con un **10.91%**, impulsada por la dispersión demográfica y barreras de accesibilidad geográfica.
- **Santa Cruz** presenta un porcentaje crítico del **8.69%**, asociado a dinámicas de migración interna y presión por inserción laboral temprana en zonas periurbanas.
- Departamentos como **Tarija (7.64%)**, **Beni (7.35%)**, **Potosí (7.25%)** y **La Paz (6.40%)** muestran niveles intermedios de alerta.

- **Cochabamba (5.70%)** y **Oruro (5.55%)** registran las tasas relativas más bajas de inasistencia dentro del periodo analizado.

B. Análisis Multivariado (Sunburst: Departamento, Área y Sexo)

El desglose multivariado mediante diagramas Sunburst demuestra que la deserción no afecta de forma homogénea a la población:

- El abandono escolar se concentra de manera desproporcionada en las zonas rurales de los departamentos con mayor extensión territorial.
- Se identifican diferencias sutiles pero relevantes entre géneros en las transiciones hacia la educación secundaria superior, donde los jóvenes varones muestran mayores tasas de salida temprana por actividades agropecuarias o laborales, mientras que las mujeres enfrentan barreras asociadas a tareas de cuidado o economía del hogar.

C. Segmentación Socioeconómica mediante Clustering (K-Means)

Mediante un modelo de agrupamiento no supervisado con el algoritmo K-Means basado en variables de edad, área geográfica y acceso tecnológico, se segmentó a la población escolar en tres perfiles socioeconómicos diferenciados:

- **Clúster 1 (Mayoritario):** 8,398 individuos con condiciones estables de escolaridad urbana.
- **Clúster 0:** 2,499 individuos con vulnerabilidad moderada.
- **Clúster 2:** 843 individuos concentrados en perfiles de alta vulnerabilidad estructural y riesgo crítico de abandono.

Imagen: Valores únicos en condición de asistencia:

```
Valores únicos en condición de asistencia:
condicion_asistencia
Asiste            10897
No matriculado      829
No asiste            14
Name: count, dtype: int64

Distribución ajustada de la variable objetivo (Deserción):
desercion
0    92.819421
1     7.180579
Name: proportion, dtype: float64
```

Imagen: Tasa de Deserción Escolar por Departamento (Bolivia 2025)

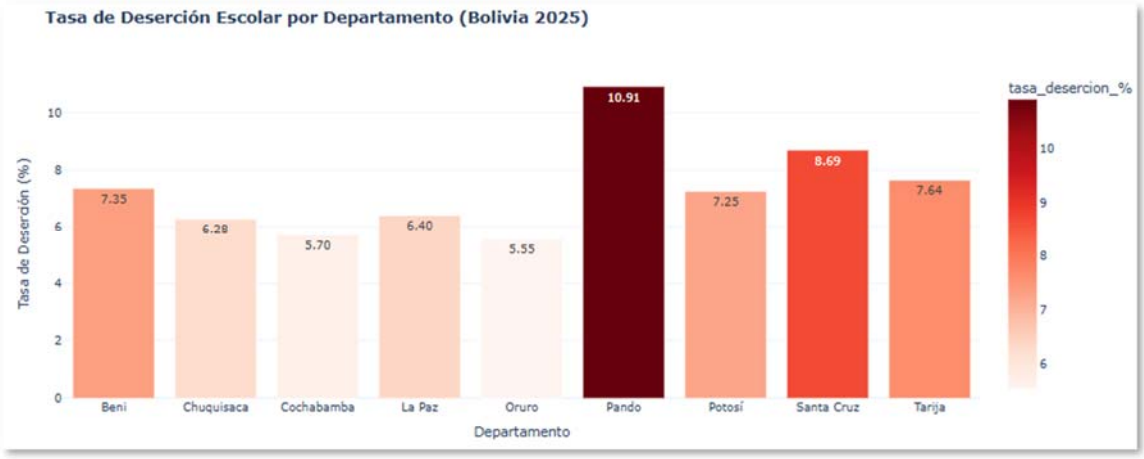
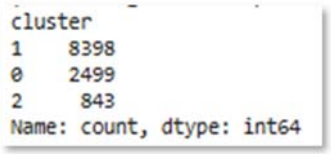


Imagen: Sunburst Multivariado: Estudiantes y Tasa de Deserción por Departamento, Área y Sexo



Imagen: Klustering K-Means



4. Recomendaciones de Políticas Públicas Basadas en Evidencia

Para predecir el riesgo de deserción y evitar problemas de sesgo o fuga de datos (*data leakage*), se entrenaron algoritmos supervisados utilizando validación cruzada estratificada de 5 particiones (`StratifiedKFold`). La matriz de entrenamiento contó con 11,740 observaciones y 5 características principales (`X` con dimensiones de 11,740 x 5).

Rendimiento de los Modelos:

- **Random Forest (Sin Fuga de Datos):** AUC-ROC Promedio de **0.8679** (± 0.0141).
- **XGBoost (Sin Fuga de Datos):** AUC-ROC Promedio de **0.8788** (± 0.0131), demostrando una excelente capacidad discriminatoria y robustez estadística ante el desbalance de clases.

Importancia de Variables (XAI):

El análisis de importancia relativa del modelo XGBoost demostró que los factores que explican la probabilidad de abandono escolar son:

1. **Edad (`edad`):** Con la mayor importancia relativa (>0.50), evidenciando que el riesgo se intensifica drásticamente en la adolescencia (12 a 18 años).
2. **Perfil Socioeconómico (`cluster`):** Segundo predictor en peso analítico, reflejando que las carencias estructurales del hogar condicionan la permanencia escolar.
3. **Área Geográfica (`area_num`):** Distingue las brechas estructurales entre el entorno urbano y rural.
4. **Acceso a Tecnologías (`internet_num`):** Refleja la brecha digital como limitante de continuidad pedagógica.
5. **Sexo (`sexo_num`):** Incidencia demográfica complementaria.

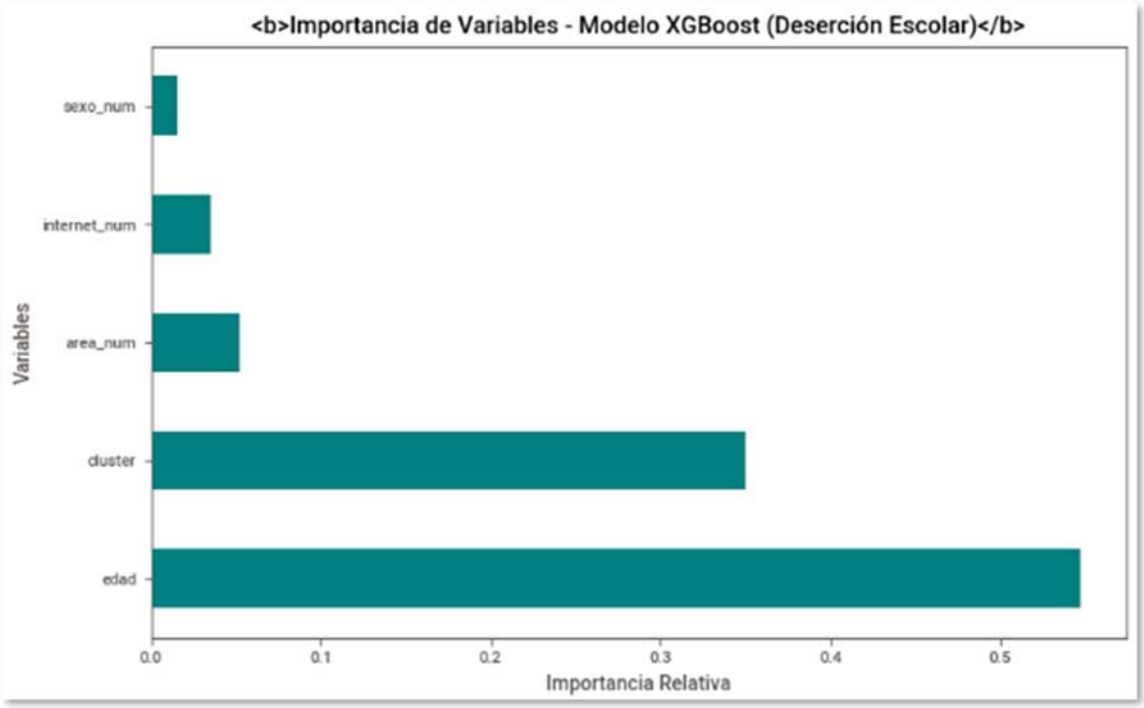
Imagen: Dimensiones de X para entrenamiento

```
Dimensiones de X para entrenamiento: (11740, 5)
Distribución de la clase objetivo:
desercion
0    10897
1      843
Name: count, dtype: int64

--- Random Forest (Sin Fuga de Datos) ---
AUC-ROC Promedio (CV 5-folds): 0.8679 (+/- 0.0141)

--- XGBoost (Sin Fuga de Datos) ---
AUC-ROC Promedio (CV 5-folds): 0.8788 (+/- 0.0131)
```

Imagen: Importancia de Variables – Modelo XGBoost (Deserción Escolar)



5. Recomendaciones de Políticas Públicas Basadas en Evidencia

A partir de los hallazgos empíricos del modelo de Machine Learning y la segmentación socioeconómica, se proponen tres directrices estratégicas de intervención pública:

1. **Implementación de un Sistema de Alerta Temprana (SAT) Escolar:**
    - *Fundamento Empírico:* La variable edad es el principal predictor del riesgo de abandono, concentrándose en los umbrales de transición hacia la secundaria superior.

- *Acción:* Establecer mecanismos automatizados en los establecimientos educativos para detectar ausencias prolongadas y prevenir la deserción asociada a la inserción laboral temprana.

2. **Cierre Focalizado de la Brecha Digital Educativa:**
   - *Fundamento Empírico:* El acceso a internet (`internet_num`) y el área geográfica estructuran los clústeres de mayor vulnerabilidad y exclusión educativa.
   - *Acción:* Priorizar programas nacionales de conectividad gratuita y la dotación de plataformas y contenidos pedagógicos offline en los municipios y departamentos con tasas críticas de abandono.
3. **Escalamiento Progresivo de Transferencias Monetarias Condicionadas:**
   - *Fundamento Empírico:* La segmentación por Clústeres K-Means evidenció que los hogares con carencias múltiples sufren un alto costo de oportunidad al mantener a sus hijos estudiando en lugar de trabajando.
   - *Acción:* Reorientar y fortalecer incentivos como el Bono Juancito Pinto y becas de retención, incrementando el monto de manera progresiva conforme el estudiante avanza en los cursos superiores de secundaria.

6. Integración de Visualizaciones y Resultados Clave

- **Mapas y Gráficos Interactivos (Plotly):** Las visualizaciones por departamento y el diagrama Sunburst reflejan la interacción crítica entre el área geográfica, el sexo y la condición de asistencia.
- **Importancia de Variables (XGBoost):** El gráfico de importancia confirma analíticamente que las características demográficas (edad) y las condiciones socioeconómicas del hogar explican el fenómeno de la deserción escolar en Bolivia.

📌 Referencia y Citación Formal

- Instituto Nacional de Estadística (INE), *Encuesta de Hogares 2025 (EH2025)*. Disponible en: http://anda.ine.gob.bo/index.php/catalog/256.
- El catalogo tiene los siguientes documentos:
  - EH2025_Discriminacion.sav
  - EH2025_Equipamiento.sav

- EH2025_Gastos_Alimentarios.sav
- EH2025_Gastos_No_Alimentarios.sav
- EH2025_Persona.sav
- EH2025_Seguridad_Alimentaria.sav
- EH2025_Vivienda_1.sav